

Prédire aussi bien que les meilleurs

(Et en plus en faisant des maths!)

Pierre Alquier



Les mercredis mathématiques du CIRM
28 novembre 2018





Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM

67%

Match nul

21%

Stade de Reims

12%



Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 – 1

Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 – 1

Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 – 1



1 – 1



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 – 1

1 – 1

Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 — 1



1 — 1



2 — 0

Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 — 1



1 — 1



2 — 0



Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 — 1



1 — 1



2 — 0



3 — 0

Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 — 1



1 — 1



2 — 0



3 — 0



Ligue 1 · 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



2 — 1



1 — 1



2 — 0



3 — 0



0 — 1

Ligue 1 - 02/12, 16:00



OM

contre



Stade de Reims

COMPOSITION

STATISTIQUES

ACTU

PROBABILITÉ DE VICTOIRE

OM
67%

Match nul
21%

Stade de Reims
12%



V



ND



V



V



ND

OBJECTIF

Apprendre à prédire aussi bien que le meilleur pronostiqueur.

OBJECTIF

Apprendre à prédire aussi bien que le meilleur pronostiqueur.
De façon générale : on parle plutôt d'**expert**.

OBJECTIF

Apprendre à prédire aussi bien que le meilleur pronostiqueur.
De façon générale : on parle plutôt d'**expert**.

- 1 En général, c'est assez difficile (on verra à la fin).

OBJECTIF

Apprendre à prédire aussi bien que le meilleur pronostiqueur.
De façon générale : on parle plutôt d'**expert**.

- 1 En général, c'est assez difficile (on verra à la fin).
- 2 Le problème devient plus facile si il existe un expert qui ne se trompe jamais.

OBJECTIF

Apprendre à prédire aussi bien que le meilleur pronostiqueur.
De façon générale : on parle plutôt d'**expert**.

- 1 En général, c'est assez difficile (on verra à la fin).
- 2 Le problème devient plus facile si il existe un expert qui ne se trompe jamais.



Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$

V

ND

V

V

ND

V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$

V

ND

V

V

ND

V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$

V

ND

V

V

ND

V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	V		ND

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND
$t = 3$	V		ND			V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND
$t = 3$	V		<u>ND</u>			V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND
$t = 3$	V		<u>ND</u>			V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND
$t = 3$	V		<u>ND</u>			V
$t = 4$	ND					V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND
$t = 3$	V		<u>ND</u>			V
$t = 4$	<u>ND</u>					V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND
$t = 3$	V		<u>ND</u>			V
$t = 4$	<u>ND</u>					V

Algorithme consistant

Suivre un expert qui ne s'est jamais trompé.



$t = 1$	V	<u>ND</u>	V	V	ND	V
$t = 2$	ND		ND	<u>V</u>		ND
$t = 3$	V		<u>ND</u>			V
$t = 4$	<u>ND</u>					V
$t = 5$						<u>V</u>

Théorème

En considérant n experts, dont l'un ne se trompe jamais, en utilisant l'algorithme *consistent*, je commettrai au plus $n - 1$ erreurs.

Théorème

En considérant n experts, dont l'un ne se trompe jamais, en utilisant l'algorithme *consistent*, je commettrai au plus $n - 1$ erreurs.

$$\text{Err}_t(\text{consistent}) \leq n - 1.$$

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$

V

ND

V

V

ND

V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$

V

ND

V

V

ND

V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$

V

ND

V

V

ND

V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	ND		ND	V		ND

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>
$t = 3$	V		ND			V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>
$t = 3$	<u>V</u>		ND			<u>V</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>
$t = 3$	<u>V</u>		ND			<u>V</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>
$t = 3$	<u>V</u>		ND			<u>V</u>
$t = 4$	ND					V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>
$t = 3$	<u>V</u>		ND			<u>V</u>
$t = 4$	<u>ND</u>					V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>
$t = 3$	<u>V</u>		ND			<u>V</u>
$t = 4$	<u>ND</u>					<u>V</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	<u>V</u>	ND	<u>V</u>	<u>V</u>	ND	<u>V</u>
$t = 2$	<u>ND</u>		<u>ND</u>	V		<u>ND</u>
$t = 3$	<u>V</u>		ND			<u>V</u>
$t = 4$	<u>ND</u>					<u>V</u>
$t = 5$						<u>V</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$

V

ND

ND

ND

ND

V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$

V

ND

ND

ND

ND

V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$

V

ND

ND

ND

ND

V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	V	<u>ND</u>	<u>ND</u>	<u>ND</u>	<u>ND</u>	V
$t = 2$	ND					ND

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	V	<u>ND</u>	<u>ND</u>	<u>ND</u>	<u>ND</u>	V
$t = 2$	<u>ND</u>					<u>ND</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	V	<u>ND</u>	<u>ND</u>	<u>ND</u>	<u>ND</u>	V
$t = 2$	<u>ND</u>					<u>ND</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	V	<u>ND</u>	<u>ND</u>	<u>ND</u>	<u>ND</u>	V
$t = 2$	<u>ND</u>					<u>ND</u>
$t = 3$	ND					V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	V	<u>ND</u>	<u>ND</u>	<u>ND</u>	<u>ND</u>	V
$t = 2$	<u>ND</u>					<u>ND</u>
$t = 3$	<u>ND</u>					V

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	V	<u>ND</u>	<u>ND</u>	<u>ND</u>	<u>ND</u>	V
$t = 2$	<u>ND</u>					<u>ND</u>
$t = 3$	<u>ND</u>					<u>V</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	V	<u>ND</u>	<u>ND</u>	<u>ND</u>	<u>ND</u>	V
$t = 2$	<u>ND</u>					<u>ND</u>
$t = 3$	<u>ND</u>					<u>V</u>
$t = 4$						<u>V</u>

Algorithme halving

Suivre la majorité des experts qui ne se sont pas trompés.



$t = 1$	V	<u>ND</u>	<u>ND</u>	<u>ND</u>	<u>ND</u>	V
$t = 2$	<u>ND</u>					<u>ND</u>
$t = 3$	<u>ND</u>					<u>V</u>
$t = 4$						<u>V</u>
$t = 5$						<u>V</u>

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10 \xrightarrow{4} 5$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10 \xrightarrow{4} 5 \xrightarrow{5} 2.5$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10 \xrightarrow{4} 5 \xrightarrow{5} 2.5 \xrightarrow{6} 1.25$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10 \xrightarrow{4} 5 \xrightarrow{5} 2.5 \xrightarrow{6} 1.25 \xrightarrow{7} 0.625$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10 \xrightarrow{4} 5 \xrightarrow{5} 2.5 \xrightarrow{6} 1.25 \xrightarrow{7} 0.625$$

Donc *halving* commet au plus 6 erreurs si $n = 80$.

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10 \xrightarrow{4} 5 \xrightarrow{5} 2.5 \xrightarrow{6} 1.25 \xrightarrow{7} 0.625$$

Donc *halving* commet au plus 6 erreurs si $n = 80$.

Le nombre d'erreurs E vérifie

$$1 \leq \frac{n}{2^E} = \frac{n}{2 \times \dots \times 2}.$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10 \xrightarrow{4} 5 \xrightarrow{5} 2.5 \xrightarrow{6} 1.25 \xrightarrow{7} 0.625$$

Donc *halving* commet au plus 6 erreurs si $n = 80$.

Le nombre d'erreurs E vérifie

$$1 \leq \frac{n}{2^E} = \frac{n}{2 \times \dots \times 2}.$$

Autrement dit

$$2^E \leq n.$$

Donc : le nombre d'erreurs commises par *halving* est au plus le nombre de fois que je peux diviser n par deux en restant ≥ 1 ...

Exemple :

$$n = 80 \xrightarrow{1} 40 \xrightarrow{2} 20 \xrightarrow{3} 10 \xrightarrow{4} 5 \xrightarrow{5} 2.5 \xrightarrow{6} 1.25 \xrightarrow{7} 0.625$$

Donc *halving* commet au plus 6 erreurs si $n = 80$.

Le nombre d'erreurs E vérifie

$$1 \leq \frac{n}{2^E} = \frac{n}{2 \times \cdots \times 2}.$$

Autrement dit

$$2^E \leq n.$$

$$E \leq \log_2(n).$$

Théorème

En considérant n experts, dont l'un ne se trompe jamais, en utilisant l'algorithme *halving*, je commettrai au plus $\log_2(n)$ erreurs.

Théorème

En considérant n experts, dont l'un ne se trompe jamais, en utilisant l'algorithme *halving*, je commettrai au plus $\log_2(n)$ erreurs.

$$\text{Err}_t(\text{halving}) \leq \log_2(n).$$

Théorème

En considérant n experts, dont l'un ne se trompe jamais, en utilisant l'algorithme *halving*, je commettrai au plus $\log_2(n)$ erreurs.

$$\text{Err}_t(\text{halving}) \leq \log_2(n).$$

Exemple : si on suit $n = 1247$ experts,

$$\text{Err}_t(\text{consistent}) \leq n - 1 = 1246$$

$$\text{Err}_t(\text{halving}) \leq \log_2(n) \simeq 10.28$$

Théorème

En considérant n experts, dont l'un ne se trompe jamais, en utilisant l'algorithme *halving*, je commettrai au plus $\log_2(n)$ erreurs.

$$\mathbf{Err}_t(\text{halving}) \leq \log_2(n).$$

Exemple : si on suit $n = 1247$ experts,

$$\mathbf{Err}_t(\text{consistent}) \leq n - 1 = 1246$$

$$\mathbf{Err}_t(\text{halving}) \leq \log_2(n) \simeq 10.28$$

$$\Rightarrow \mathbf{Err}_t(\text{halving}) \leq 10$$





Le gouvernement vous ment !



Le gouvernement vous ment !

Le Père Noël n'existe pas !



Le gouvernement vous ment !

Le Père Noël n'existe pas !



halving : nombre de “voix” données à chaque expert.



1



1



1



1



1

halving : nombre de “voix” données à chaque expert.



0



1



0



0



1

halving : nombre de “voix” données à chaque expert.



0



1

1



0



0



1

1

halving : nombre de “voix” données à chaque expert.



0



1

1



0



0



1

0

halving : nombre de “voix” données à chaque expert.



0



1

1

1



0



0



1

0

halving : nombre de “voix” données à chaque expert.



0



1

1

0



0



0



1

0

mult.upt. : ne jamais éliminer complètement un expert.



1



1



1



1



1

mult.upt. : ne jamais éliminer complètement un expert.



$\frac{1}{2}$



1



$\frac{1}{2}$



$\frac{1}{2}$



1

mult.upt. : ne jamais éliminer complètement un expert.



$$\frac{1}{2}$$

$$\frac{1}{2}$$



$$1$$

$$1$$



$$\frac{1}{2}$$

$$\frac{1}{2}$$



$$\frac{1}{2}$$

$$\frac{1}{2}$$



$$1$$

$$1$$

mult.upt. : ne jamais éliminer complètement un expert.



$$\frac{1}{2}$$

$$\frac{1}{2}$$



$$1$$

$$1$$



$$\frac{1}{2}$$

$$\frac{1}{2}$$



$$\frac{1}{2}$$

$$\frac{1}{4}$$



$$1$$

$$\frac{1}{2}$$

mult.upt. : ne jamais éliminer complètement un expert.



$$\frac{1}{2}$$

$$\frac{1}{2}$$

$$\frac{1}{2}$$



$$1$$

$$1$$

$$1$$



$$\frac{1}{2}$$

$$\frac{1}{2}$$

$$\frac{1}{2}$$



$$\frac{1}{2}$$

$$\frac{1}{4}$$

$$\frac{1}{4}$$



$$1$$

$$\frac{1}{2}$$

$$\frac{1}{2}$$

mult.upt. : ne jamais éliminer complètement un expert.



$$\frac{1}{2}$$

$$\frac{1}{2}$$

$$\frac{1}{4}$$



$$1$$

$$1$$

$$\frac{1}{2}$$



$$\frac{1}{2}$$

$$\frac{1}{2}$$

$$\frac{1}{2}$$



$$\frac{1}{2}$$

$$\frac{1}{4}$$

$$\frac{1}{8}$$



$$1$$

$$\frac{1}{2}$$

$$\frac{1}{4}$$

Théorème

$$\mathbf{Err}_t(\text{EWA}) \leq \mathbf{Err}_t(\text{meilleur expert}) + \text{Regret}(t)$$

et

$$\frac{\text{Regret}(t)}{t} \xrightarrow[t \rightarrow \infty]{} 0.$$

Une version un peu plus générale et formalisée du résultat,
extraite de la thèse de Sébastien Gerchinovitz.

Une version un peu plus générale et formalisée du résultat, extraite de la thèse de Sébastien Gerchinovitz.

Lemma 1. Assume that for some known constant $B_y > 0$,

$$y_1, \dots, y_T \in [-B_y, B_y].$$

For all $\tau > 0$, if the algorithm $\text{SeqSEW}_\tau^{B, \eta}$ is used with $B \geq B_y$ and $\eta \leq 1/(8B^2)$, then it satisfies

$$(14) \quad \sum_{t=1}^T (y_t - \hat{y}_t)^2 \leq \inf_{\rho \in \mathcal{M}_1^+(\mathbb{R}^d)} \left\{ \int_{\mathbb{R}^d} \sum_{t=1}^T \left(y_t - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B \right)^2 \rho(d\mathbf{u}) + \frac{\mathcal{K}(\rho, \pi_\tau)}{\eta} \right\}$$

$$(15) \quad \leq \inf_{\rho \in \mathcal{M}_1^+(\mathbb{R}^d)} \left\{ \int_{\mathbb{R}^d} \sum_{t=1}^T (y_t - \mathbf{u} \cdot \boldsymbol{\varphi}(x_t))^2 \rho(d\mathbf{u}) + \frac{\mathcal{K}(\rho, \pi_\tau)}{\eta} \right\}.$$

Proof (of Lemma 7). As is usually done in the online learning setting for the study of the Exponentially Weighted Average Forecaster, our proof relies on the control of $\sum_t \eta^{-1} \ln(W_{t+1}/W_t)$ where we recall that $W_1 \triangleq 1$ and, for all $t \geq 2$,

$$W_t \triangleq \int_{\mathbb{R}^d} \exp \left(-\eta \sum_{s=1}^{t-1} \left(y_s - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_s)]_B \right)^2 \right) \pi_\tau(\mathbf{d}\mathbf{u}) .$$

On the one hand, we have

$$\begin{aligned} \frac{1}{\eta} \ln \frac{W_{T+1}}{W_1} &= \frac{1}{\eta} \ln \int_{\mathbb{R}^d} \exp \left(-\eta \sum_{t=1}^T \left(y_t - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B \right)^2 \right) \pi_\tau(\mathbf{d}\mathbf{u}) - \frac{1}{\eta} \ln 1 \\ (16) \quad &= \frac{1}{\eta} \sup_{\rho \in \mathcal{M}_1^+(\mathbb{R}^d)} \left\{ \int_{\mathbb{R}^d} \left(-\eta \sum_{t=1}^T \left(y_t - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B \right)^2 \right) \rho(\mathbf{d}\mathbf{u}) - \mathcal{K}(\rho, \pi_\tau) \right\} - 0 \end{aligned}$$

$$(17) \quad = - \inf_{\rho \in \mathcal{M}_1^+(\mathbb{R}^d)} \left\{ \int_{\mathbb{R}^d} \sum_{t=1}^T \left(y_t - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B \right)^2 \rho(\mathbf{d}\mathbf{u}) + \frac{\mathcal{K}(\rho, \pi_\tau)}{\eta} \right\} ,$$

where (16) follows from a convex duality argument for the Kullback-Leibler divergence (cf., e.g., [DZ98 p. 264] or [Cat04 p. 159]) which we recall in Proposition 5 in the Appendix.

On the other hand, we can rewrite W_{T+1}/W_1 as a telescopic product and get

$$\begin{aligned}
\frac{1}{\eta} \ln \frac{W_{T+1}}{W_1} &= \sum_{t=1}^T \frac{1}{\eta} \ln \frac{W_{t+1}}{W_t} \\
&= \sum_{t=1}^T \frac{1}{\eta} \ln \int_{\mathbb{R}^d} \frac{\exp \left(-\eta \left(y_t - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B \right)^2 \right) \exp \left(-\eta \sum_{s=1}^{t-1} \left(y_s - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_s)]_B \right)^2 \right)}{W_t} \pi_{\tau}(\mathbf{d}\mathbf{u}) \\
(18) \quad &= \sum_{t=1}^T \frac{1}{\eta} \ln \int_{\mathbb{R}^d} \exp \left(-\eta \left(y_t - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B \right)^2 \right) p_t(\mathbf{d}\mathbf{u}) ,
\end{aligned}$$

where (18) follows from the definition of p_t .

Let $t \in \{1, \dots, T\}$. First note that by assumption $y_t \in [-B_y, B_y] \subset [-B, B]$ so that both y_t and $[\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B$ are $[-B, B]$ -valued for all $\mathbf{u} \in \mathbb{R}^d$. Moreover, from Proposition 6 in the Appendix, the square loss is $1/(8B^2)$ -exp-concave on $[-B, B]$ and thus η -exp-concave (since $\eta \leq 1/(8B^2)$ by assumption). Therefore, by Jensen's inequality,

$$\int_{\mathbb{R}^d} e^{-\eta \left(y_t - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B \right)^2} p_t(\mathbf{d}\mathbf{u}) \leq \exp \left(-\eta \left(y_t - \int_{\mathbb{R}^d} [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B p_t(\mathbf{d}\mathbf{u}) \right)^2 \right) .$$

Taking the logarithms of both sides of the inequality yields

$$\begin{aligned}
 \ln \int_{\mathbb{R}^d} e^{-\eta(y_t - [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B)^2} p_t(d\mathbf{u}) &\leq -\eta \left(y_t - \int_{\mathbb{R}^d} [\mathbf{u} \cdot \boldsymbol{\varphi}(x_t)]_B p_t(d\mathbf{u}) \right)^2 \\
 (19) \qquad \qquad \qquad &= -\eta(y_t - \hat{y}_t)^2.
 \end{aligned}$$

Dividing the latter inequality by η , summing over $t \in \{1, \dots, T\}$ and combining with Equation (18), we get

$$(20) \qquad \qquad \qquad \frac{1}{\eta} \ln \frac{W_{T+1}}{W_1} \leq - \sum_{t=1}^T (y_t - \hat{y}_t)^2.$$

Putting Inequalities (17) and (20) together, we get Inequality (14) of Lemma 1. As for Inequality (15), it follows from (14) by noting that

$$\forall y \in [-B, B], \quad \forall x \in \mathbb{R}, \quad |y - [x]_B| \leq |y - x|,$$

so that truncation to $[-B, B]$ can only improve prediction under the square loss if the observations are $[-B, B]$ -valued, which is the case here since by assumption $y_t \in [-B_y, B_y] \subset [-B, B]$ for all $t = 1, \dots, T$. \square




POURQUOI,
POURQUOI,
POURQUOI ?



POURQUOI,
POURQUOI,
POURQUOI ?








Prédiction de la qualité de l'air par différents experts, utilisant différents modèles physiques.





Cours du change Euro/Dollar.

Ce qu'il faut savoir sur la grippe saisonnière

La grippe est une maladie causée par les virus grippaux saisonniers. C'est l'une des principales d'une personne à l'autre.

Comment reconnaître la grippe?



Fièvre élevée soudaine



Mal de tête



Toux ou mal de gorge



Douleurs musculaires

Que faire quand vous avez la grippe?



Quand vous toussiez, éternuez ou avez la grippe, couvrez-vous bien avec votre coude ou votre bras pliés.



Boire beaucoup d'eau pour rester hydraté.



Reposer-vous.



Prendre les médicaments prescrits.



Consultez un médecin, un infirmier ou un pharmacien si vous ne vous sentez pas mieux ou si vous avez des symptômes graves.



Organisation mondiale de la Santé

D'URGENCES

Comment prévenir la grippe?

Se faire vacciner contre la grippe chaque année est le meilleur moyen de prévenir la grippe.



La vaccination est particulièrement importante pour les personnes à haut risque de complications secondaires suite à une grippe.

- Personnes âgées
- Les personnes de plus de 65 ans
- Les enfants de 6 mois à 5 ans
- Les personnes souffrant de problèmes de santé chroniques
- Les personnes qui vivent avec des personnes ou des animaux à haut risque

Ce qu'il faut savoir sur la grippe saisonnière

La grippe est une maladie causée par les virus grippaux saisonniers. C'est l'une des principales d'une personne à l'autre.

Comment reconnaître la grippe?



Fèvre élevée soudaine



Mal de tête



Toux ou mal de gorge



Douleurs musculaires

Que faire quand vous avez la grippe?



Couvrir votre nez lorsque vous toussez ou éternuez avec votre bras ou votre coude.



Lavez-vous les mains fréquemment avec du savon et de l'eau.



Reposez-vous.



Boivez beaucoup d'eau et mangez des aliments nutritifs.



Consultez un médecin, si vous le devez, surtout si vous êtes âgé, si vous êtes enceinte ou si vous avez une maladie chronique.



Organisation mondiale de la Santé

D'URGENCES


Comment prévenir la grippe?

Se faire vacciner contre la grippe chaque année est le meilleur moyen de prévenir la grippe.



La vaccination est particulièrement importante pour les personnes à haut risque de complications secondaires suite à une grippe :

- Personnes âgées
- Les personnes de plus de 65 ans
- Les enfants de 6 mois à 5 ans
- Les personnes souffrant de problèmes de santé chroniques
- Les personnes qui vivent avec des personnes à haut risque



Ce qu'il faut savoir sur la grippe saisonnière

La grippe est une maladie causée par les virus grippaux saisonniers. Ces virus se propagent d'une personne à l'autre.

Comment reconnaître la grippe?



Fèvre élevée soudaine



Mal de tête



Toux ou mal de gorge



Douleurs musculaires

Que faire quand vous avez la grippe?



Couvrir votre toux ou éternuement avec votre bras ou un mouchoir en papier.



Lavage des mains soigneux et fréquent avec du savon.



Reposer votre corps.



Prendre des médicaments si nécessaire.



Consultez un médecin, un infirmier ou un pharmacien si vous avez des symptômes graves ou si vous faites partie d'un groupe à risque élevé.



Organisation mondiale de la Santé

D'URGENCES


Comment prévenir la grippe?

Se faire vacciner contre la grippe chaque année est le meilleur moyen de prévenir la grippe.




La vaccination est particulièrement importante pour les personnes à haut risque de complications secondaires suite à une grippe :

- Personnes âgées
- Les personnes de plus de 65 ans
- Les enfants de 6 mois à 5 ans
- Les personnes souffrant de problèmes de santé chroniques
- Les personnes qui vivent avec une personne à haut risque



© IRSAN



CONCLUSION

FAITES DES MATHS
FAITES DE L'INFORMATIQUE
Vous en aurez besoin PARTOUT

CONCLUSION

FAITES DES MATHS
FAITES DE L'INFORMATIQUE
Vous en aurez besoin PARTOUT

References :

- ❶ L'étude de l'algorithme halving est tirée de [1].
- ❷ L'exemple sur la pollution de l'air est tiré de [2].
- ❸ L'étude de l'algorithme mult.up est copié-collée de [3].
- ❹ Les cartes et séries épidémiologiques sont tirées du site <https://sites.sentiweb.fr/>.



[1] S. Shalev-Shwartz. Online learning and online convex optimization. *Foundations and Trends in Machine Learning*, 2012.



[2] G. Stoltz. Agrégation séquentielle de prédicteurs : méthodologie générale et applications à la prévision de la qualité de l'air et à celle de la consommation électrique. *Journal de la SFDS*, 2010.



[3] S. Gerchinovitz. Prédiction de suites individuelles et cadre statistique classique : étude de quelques liens autour de la régression parcimonieuse et des techniques d'agrégation. *Thèse de doctorat, Université Paris Sud*, 2011.